Analyse du phénomène « Hot Hand » à partir de données de parties d'échecs

Projet d'analyse statistique et empirique

Auteurs :

BERLIA Alexandre, DUVERDIER Matthieu, MEIRA Gabriel, SUTTER Robinson

Coordinateurs :

BERGEAUD Antonin, MALGOUYRES Clément

2025-2026

Table des matières

Introduction **1**

1 Première preuve visuelle : permutation test **1**

2 Identification causale : Diff-in-Diff **1**
2.a Résultat principal 2
2.b Hétérogénéité selon le niveau Elo 2
2.c Hétérogénéité selon la cadence 2
2.d Tournois 2
2.e Cas de triche 2

3 Robustesse : régressions logit **3**
3.a Spécification binaire 3
3.b Spécification linéaire 3
3.c Spécification catégorielle 3
3.d Interaction Elo $\times$ k 3

4 Mécanisme : modèles à état latent **3**
4.a Modèle AR(1) 3
4.b Filtre de Kalman (en cours) 4

5 Discussion **4**
5.a Biais et robustesse 4
5.b Magnitude économique 4
5.c Mécanisme psychologique 4
5.d Limites et extensions 5

6 Conclusion **5**

Bibliographie **Annexe 1**

Annexes : Graphiques et résultats **Annexe 1**

Introduction

Le phénomène du *« hot hand »* est un concept psychologique et statistique selon lequel un individu connaissant une série de succès aurait une probabilité accrue de réussir ses actions suivantes. Longtemps discuté en économie comportementale et en psychologie, ce phénomène a été particulièrement étudié dans le sport (basket-ball, baseball, tennis), mais rarement dans le cadre des échecs.

Le système ELO, qui mesure la force d'un joueur d'échecs par un indicateur probabiliste de victoire contre un joueur classé, suppose que la performance d'un joueur reste relativement stable à court terme. En théorie, la fréquence des parties n'influe pas le gain ou la perte de points. Si le *hot hand* existe réellement, cela indiquerait une limite du modèle actuel : il ne prend pas en compte les dynamiques temporelles immédiates susceptibles d'influencer un tournoi en cours.

La plateforme en ligne *Lichess* propose des bases de données massives contenant des millions de parties jouées par des amateurs comme par des professionnels. Ces données vastement riches permettent de tester empiriquement l'existence du *hot hand* dans un environnement stratégique et intellectuel.

L'analyse repose sur des méthodes statistiques telles que test de permutation, régressions logistiques et modèle d'état latent. Enfin, la robustesse des résultats est étudiée selon différents sous-échantillons, notamment le niveau Elo, la cadence des parties et le contexte compétitif.

1 Première preuve visuelle : permutation test

La première étape de l'analyse consiste à établir une preuve non paramétrique de l'existence d'un phénomène de hot hand dans les performances des joueurs d'échecs. Pour cela, nous utilisons un test de permutation qui permet de comparer les résultats observés aux résultats attendus sous une hypothèse nulle d'indépendance entre les parties. L'idée du test est la suivante. Pour chaque joueur, on observe une séquence de résultats binaires X_t indiquant victoire, défaite ou nulle (ces dernières étant traitées séparément dans certaines spécifications). Si les résultats sont indépendants et identiquement distribués, l'ordre des parties ne doit contenir aucune information particulière. Ainsi, on peut générer une distribution nulle en permutant aléatoirement l'ordre des parties pour chaque joueur tout en conservant le nombre total de victoires et de défaites. Pour chaque longueur de série k on calcule alors la probabilité empirique de victoire après une série de k victoires consécutives dans les données observées et dans les données simulées. Cette procédure est répétée un grand nombre de fois afin d'obtenir une distribution de référence. Les résultats sont représentés graphiquement en comparant :

— la probabilité observée de victoire après une série de k victoires ;

— la distribution simulée sous l'hypothèse nulle.

La Figure 1 en annexe montre que la probabilité de victoire après une série de victoires est systématiquement supérieure à ce que prédit la distribution nulle. Autrement dit, les performances observées présentent une persistance temporelle plus forte que ce qui serait attendu si les résultats étaient indépendants. La significativité statistique de cet écart est évaluée par la proportion de simulations produisant un effet au moins aussi grand que celui observé. Dans l'ensemble des cas étudiés, on obtient une p-value $p < 0.005$ pour toutes les longueurs de série considérées. Ce résultat constitue une première preuve visuelle et non paramétrique de l'existence d'un effet de hot hand. L'avantage de cette approche est qu'elle ne repose sur aucune hypothèse paramétrique concernant la distribution des performances ou la dynamique des résultats. Cependant, cette approche reste descriptive. Elle ne permet pas d'identifier un effet causal car les séries de victoires peuvent être corrélées à d'autres facteurs, notamment le niveau du joueur ou la difficulté des adversaires. Pour répondre à cette question, nous utilisons une stratégie d'identification économétrique plus rigoureuse.

2 Identification causale : Diff-in-Diff

Afin d'identifier un effet causal de la dynamique de série sur les performances futures, nous utilisons une approche de type difference-in-differences (Diff-in-Diff). L'idée consiste à comparer l'évolution de la probabilité de victoire :

— pour les joueurs entrant dans une série de victoires supérieure à un seuil (groupe traité),

— pour les joueurs dont la série de victoire est inférieur au seuil(groupe contrôle).

Dans cette approche, on contrôle aussi l'écart de niveau entre les joueuers pour isoler l'effet dynamique associé à la série de victoires.

2.a Résultat principal

Le résultat principal montre que la probabilité de victoire après une série de plus de k victoires est significativement plus élevée que la probabilité de victoire dans les situations de référence. L'estimation Diff-in-Diff suggère donc que les joueurs ayant récemment connu plusieurs victoires consécutives présentent une performance future supérieure à celle prédite par leur niveau moyen (Figure 2). L'effet de série reste positif même après une défaite, ce qui invalide l'hypothèse d'un déclencheur unique basé uniquement sur le dernier résultat. Les résultats suggèrent plutôt que la durée de la série joue un rôle plus important que le type du dernier résultat. Une défaite isolée après une longue série peut être perçue comme de la malchance, ce qui préserve la confiance et la dynamique de performance. Autrement dit, les performances passées semblent avoir un effet dynamique sur les performances futures. Ce résultat est cohérent avec l'hypothèse d'un momentum de performance, souvent décrit dans la littérature comme un phénomène de hot hand.

2.b Hétérogénéité selon le niveau Elo

Nous examinons ensuite l'hétérogénéité de cet effet selon le niveau Elo des joueurs. Les joueurs sont répartis en différentes catégories de niveau afin d'étudier si l'effet de hot hand est plus prononcé chez certains groupes (FIGURES 4, 5, 6). Les résultats indiquent que l'effet est :

— Relativement faible chez les joueurs intermédiaires ;

— Plus marqué chez les joueurs débutants et expérimentés.

2.c Hétérogénéité selon la cadence

Nous analysons également les différences selon la cadence des parties :

— Bullet (≈1 minute)

— Blitz (≈3 minutes)

— Rapide (≈10 minutes)

— Classique (≈30 minutes)

Les résultats suggèrent que l'effet de hot hand est plus prononcé pour les cadences plus longues (FIGURE 7). Cela peut s'expliquer par le fait que les joueurs ont plus de temps pour douter ou prendre confiance. Cependant on remarque un effet plus prononcé en Bullet qu'en Blitz, mais c'est une cadence particulière relevant plus des réflexes que de la réflexion, en faisant un jeu aux mécaniques différentes d'une partie d'échec à cadence plus classique.

2.d Tournois

Une analyse spécifique est menée sur les parties disputées dans le cadre de tournois. Dans ce contexte, les incitations sont différentes. Les performances passées peuvent influencer la motivation liée au classement. Les résultats obtenus dans les tournois sont similaires avec ceux observés sur l'ensemble des parties en considérant l'écart-type (FIGURE 8).

2.e Cas de triche

L'étude analyse plusieurs facteurs susceptibles de biaiser l'observation des séries de performance (streaks) dans les parties d'échecs en ligne, en particulier les manipulations de classement. Trois comportements sont considérés : la triche, détectée via les parties terminées pour "rules infraction", le smurfing (joueurs sous-classés qui gagnent beaucoup plus que prévu) et le sandbagging (pertes intentionnelles pour baisser son classement). Les manipulations de rang sont détectées en comparant la performance observée à la performance attendue selon le modèle Elo, à l'aide d'un Z-score

$$Z_i = \frac{S_i - E_i}{\sqrt{\sum_{k=1}^{N} E_k(1 - E_k)}}$$

où les E_k correspondent à la probabilité de victoire du joueur sur sa partie numéro k, Ei à la somme des E_k pour le joueur i, et S_i à la somme des résultats observés pour le joeuur i.

On utilise également un critère sur l'écart de Elo entre le début et la fin de la période pour cibler les smurfs et sandbaggers. Les joueurs suspects sont ensuite retirés du dataset. Au total, 12 851 joueurs (0,65%) sont exclus. La comparaison des modèles et graphiques avant et après filtrage montre des résultats très similaires, avec seulement une légère réduction de l'intensité des séries de victoires (FIGURE 3 vs FIGURE 2). Cela suggère que ces comportements extrêmes ont un impact limité sur l'étude du hot hand et que les ignorer par la suite aura un impact minime.

3 Robustesse : régressions logit

Afin de vérifier la robustesse des résultats, plusieurs spécifications de régressions logistiques sont estimées.

3.a Spécification binaire

Dans la première spécification, nous introduisons une variable binaire indiquant si un joueur est dans une situation de hot hand, définie comme au moins trois victoires consécutives. La régression logit estime alors l'effet de cette variable sur la probabilité de victoire lors de la partie suivante. Les résultats indiquent que le coefficient de la variable hot hand est positif, valant 0. 086 et statistiquement significatif. Cela suggère qu'une série de victoires augmente la probabilité de succès futur de 8.6%.

3.b Spécification linéaire

Dans une seconde spécification, la longueur de la série k est introduite comme variable continue. Cette approche permet d'évaluer si la probabilité de victoire augmente progressivement avec la longueur de la série. Les résultats montrent une relation positive entre k et la probabilité de victoire future, ce qui suggère que les séries plus longues sont associées à un effet plus important. En effet le coefficient de k dans la régression vaut 0.027 ce qui implique que chaque victoire supplémentaire accroit la probabilité de gagner de 2.7%.

3.c Spécification catégorielle

Une troisième spécification distingue différentes longueurs de séries, $k = 3$, 5 et 8. Cette approche permet de tester l'existence d'un effet non linéaire des séries de victoires. Les résultats montrent que l'impact augmente avec la longueur de la série et s'accélère pour les séries très longues. La probabilité de gagner augmente de 6.9% pour k=3-4, 11.4% pour k=5-7 et 32.1% pour k>7. En probabilité absolue, pour un Elo de 1675, la probabilité de gagner passe de 47.8% à 49,5% (k=3) puis à 54,8% pour k=8. Ainsi, les probabilités de victoire progressent de plus en plus à mesure que la série s'allonge, ce qui confirme une accélération de l'effet de streak plutôt qu'un simple effet linéaire.

3.d Interaction Elo × k

Enfin, nous estimons un modèle incluant une interaction entre la longueur de la série et le niveau Elo. Cette spécification permet de tester si la dynamique de série dépend du niveau du joueur. Pour un débutant (Elo<1200), la probabilité de gagner augmente de 6.1% pour k=8 contre 4.6% pour un maître (Elo<2400). Les résultats confirment ainsi que l'effet de hot hand est plus faible chez les joueurs les mieux classés, ce qui suggère que l'expérience ou la stabilité des performances atténue les fluctuations à court terme et peut s'expliquer par le fait que les meilleurs joueurs sont plus rationnels et moins sensibles à la psychologie (FIGURE 9).

4 Mécanisme : modèles à état latent

Afin de mieux comprendre les mécanismes sous-jacents au phénomène de hot hand, nous estimons des modèles à état latent, qui permettent de modéliser l'évolution d'un niveau de performance non observé.

4.a Modèle AR(1)

Le premier modèle suppose que la performance latente d'un joueur suit un processus autorégressif :

$$\theta_t = \rho\theta_{t-1} + \varepsilon_t$$

où θ_t représente le niveau de performance instantané. Dans ce cadre, les résultats des parties sont déterminés par ce niveau latent. Les estimations réalisées sur l'ensemble de la population suggèrent l'existence d'une

dynamique positive (FIGURE 10). Dans ce cas, le ρ moyen vaut 0.002114 et le ρ moyen pondéré par N parties 0.004137 (les joueurs avec beaucoup de parties ont un ρ plus élevé). Il y a ainsi une autocorrélation positive mais économiquement négligeable ce qui implique un effet minuscule, significatif surtout grâce à la très grande taille de l'échantillon. La dispersion des ρ montre une forte dispersion entre joueurs. Les phénomènes de hot hand et cold hand coexistent et s'annulent globalement. Cependant, ces estimations peuvent être biaisées si l'hétérogénéité entre joueurs n'est pas correctement prise en compte. Pour limiter ce biais, nous restreignons l'analyse à un sous-échantillon de joueurs stables, c'est-à-dire des joueurs ayant un niveau Elo relativement constant sur la période étudiée (FIGURE 11). Ici, le ρ moyen simple vaut $-0,000687$. Cela indique un cold hand statistiquement significatif sur les joueurs stables. Mais l'effet reste économiquement négligeable : un résidu de +10% à $t-1$ ne prédit que $-0,007$ % à t. Ainsi, sans contrôle du drift, on trouve un léger hot hand (ρ=0.002) mais après restriction aux joueurs stables, le résultat devient un léger cold hand (ρ =-0.0007) : l'écart de 0,0027 reflète donc surtout un biais de progression Elo. Il n'y a donc pas de hot hand en AR(1) après correction, seulement une très légère régression à la moyenne, économiquement nulle. Cela suggère que le hot hand est un effet d'état (pendant une streak active, comme le montre le diff-in-diff à +2% pour k =3), et non un effet de lag persistant d'une partie à la suivante.

4.b Filtre de Kalman (en cours)

Une extension naturelle consiste à utiliser un filtre de Kalman pour estimer dynamiquement le niveau de performance latent. Différence vs AR(1) :
AR(1) suppose résidu = bruit blanc + mémoire simple alors que Kalman suppose état latent caché évolutif.
Modèle structurel :

$$Win_{i,t} \sim \text{Bernoulli}\left(\sigma(\alpha_i + \beta\, EloDiff + \theta_{i,t})\right)$$

$$\theta_{i,t} = \rho\, \theta_{i,t-1} + \eta_{i,t}, \qquad \eta_{i,t} \sim \mathcal{N}(0, \sigma_i^2)$$

Avantages :

- Estime des profils de joueur ; σ_i^2 élevée : joueur volatile émotionnellement (swings fréquents), σ_i^2 faible : joueur stable (talent domine)
- Détecte non-linéarités via sigmoid (AR(1) linéaire les rate)

Coût : 300 itérations d'optimisation × N joueurs (= 50h de calcul pour N = 20k)
Attendu : ρ Kalman $\approx$ ρ AR(1) stable.
Gain : profil psychologique par joueur (identifier qui est volatil pour coaching personnalisé).

5 Discussion

5.a Biais et robustesse

Plusieurs sources de biais peuvent affecter l'estimation du phénomène de hot hand. En particulier, les séries de victoires peuvent être corrélées à la qualité des adversaires rencontrés ou à des effets de sélection. Les analyses réalisées dans cette étude tentent de limiter ces biais en contrôlant le niveau Elo et en utilisant des méthodes non paramétriques et quasi-expérimentales.

5.b Magnitude économique

Au-delà de la significativité statistique, il est important d'évaluer la magnitude économique de l'effet. Les estimations suggèrent que l'augmentation de la probabilité de victoire associée aux séries de victoires reste relativement modérée. Le phénomène existe donc, mais son ampleur demeure limitée.

5.c Mécanisme psychologique

Une interprétation possible du phénomène repose sur des mécanismes psychologiques :

- augmentation de la confiance après plusieurs victoires ;
- meilleure prise de décision ;
- pression accrue sur les adversaires.

Ces mécanismes pourraient expliquer la persistance observée dans les performances.

5.d Limites et extensions

Plusieurs limites doivent être soulignées. Tout d'abord, les données utilisées ne permettent pas d'observer directement les variables psychologiques ou cognitives des joueurs. Ensuite, certaines caractéristiques des parties, comme la qualité exacte des coups, ne sont pas intégrées dans l'analyse. Des extensions possibles incluent :

— Asymétrie couleur : différence de résultats entre blancs et noirs ?

— Effet adversaire :

$$Logit(Win_A) = HH_A + HH_B + HH_A * HH_B$$

Intéraction négative attendue (deux streaks s'annulent).

— Coupure de l'état hot hand : combien de défaites ou nulles cassent complètement l'effet.

— Temporalité : moment de la journée, pause depuis la dernière partie ou non...

— Différence d'impact entre streak de 5 et 5 victoires sur 8 matchs par exemple.

6 Conclusion

En conclusion, les résultats établissent de façon très solide l'existence d'un hot hand aux échecs en ligne, avec une convergence de 9 méthodes indépendantes, toutes hautement significatives ($p<0{,}001$) et un effet économiquement substantiel de l'ordre de +2 à +6 %. L'apport principal est double : d'abord, le résultat est crédible car il repose sur plusieurs méthodes qui vont toutes dans le même sens et corrige les biais de progression ; ensuite, il montre que le hot hand est surtout un effet temporaire lié au fait d'être en série, et non un effet qui se prolonge mécaniquement d'une partie à l'autre. Cela ouvre des implications concrètes pour le coaching, la prédiction et le design des plateformes, tout en laissant une marge limitée de validation externe supplémentaire.

Bibliographie

[1] Rosenthal, Jeffrey S. (2025), *An Investigation Into Probabilities of Streaks in Online Chess*, https://probability.ca/jeff/ftpdir/chessstreaksorig.pdf

[2] Base publique Lichess (2025), https://database.lichess.org/

Annexes : Graphiques et résultats

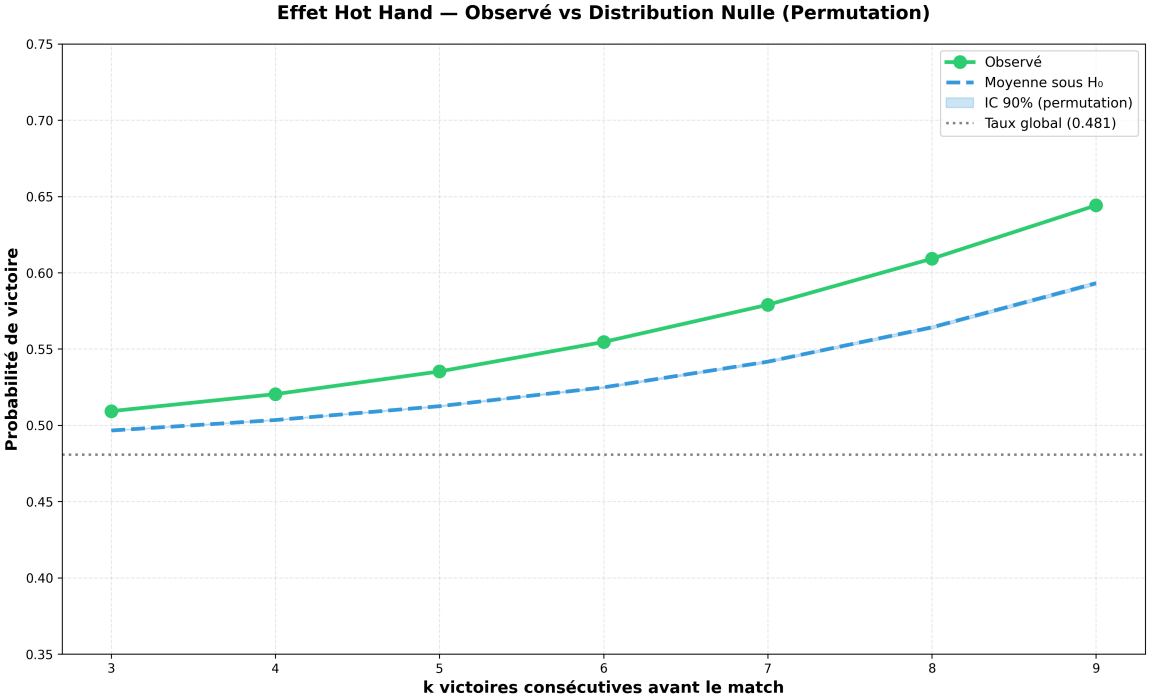

FIGURE 1 – Test de permutation

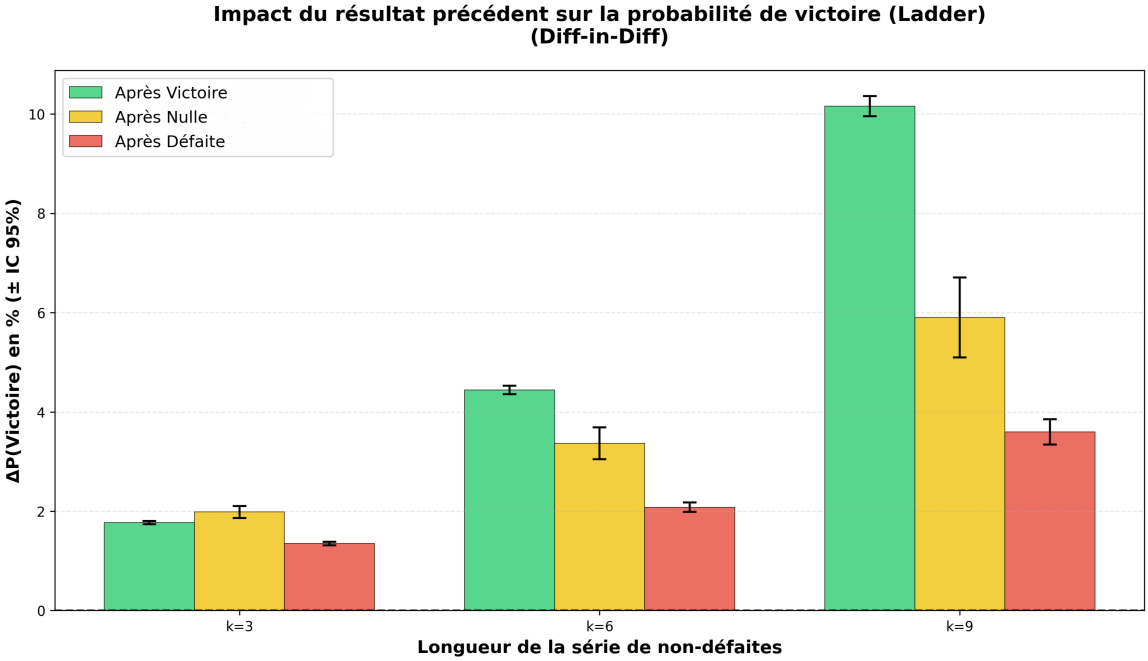

FIGURE 2 – Effet d'une série de victoires sur les chances de gagner ou de faire match nul à Elo comparable

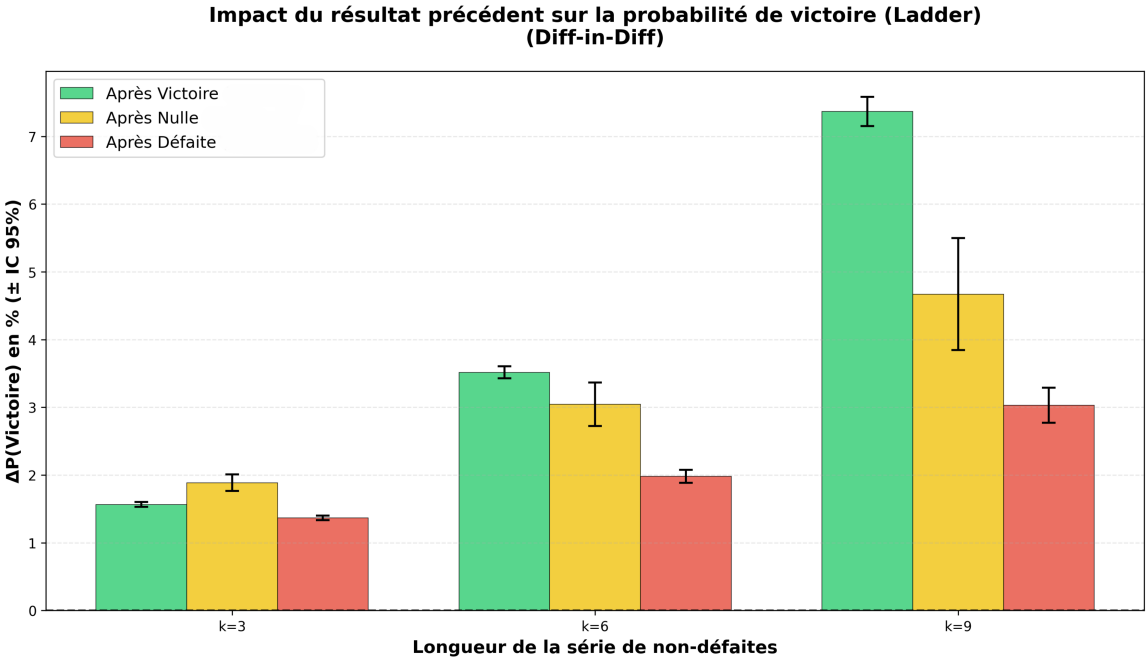

FIGURE 3 – Résultat précédent net des tricheurs et joueurs manipulant leur rang

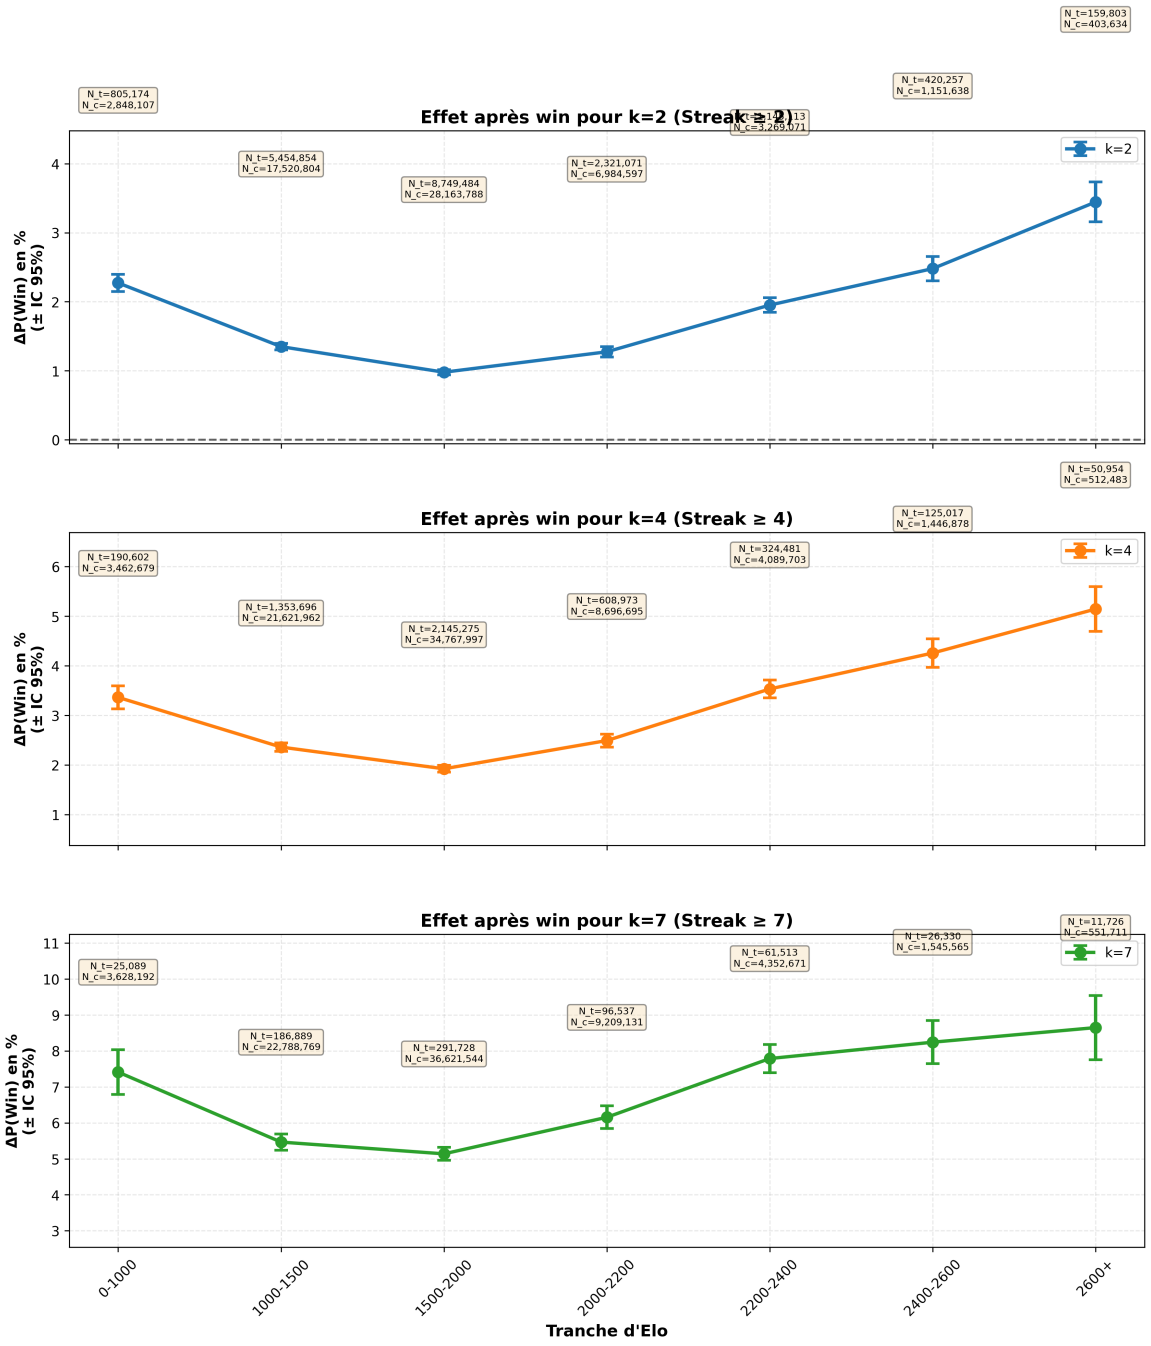

FIGURE 4 – Augmentation de la probabilité de victoire après une victoire en fonction de la tranche elo pour différentes valeurs de streak

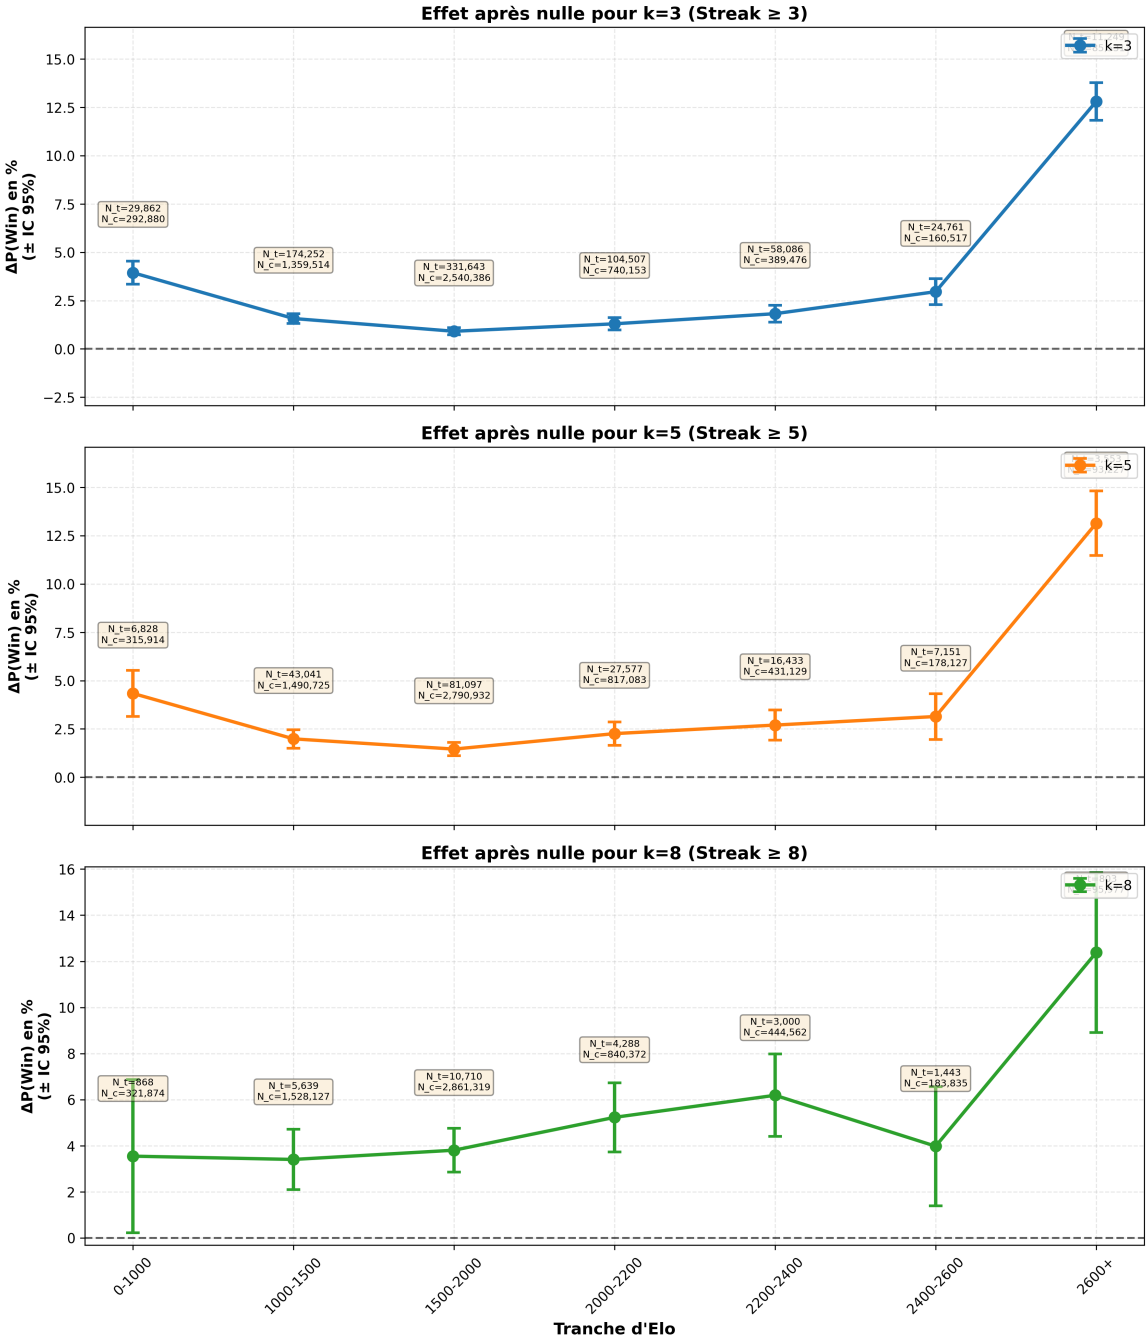

FIGURE 5 – Augmentation de la probabilité de victoire après une nulle en fonction de la tranche elo pour différentes valeurs de streak

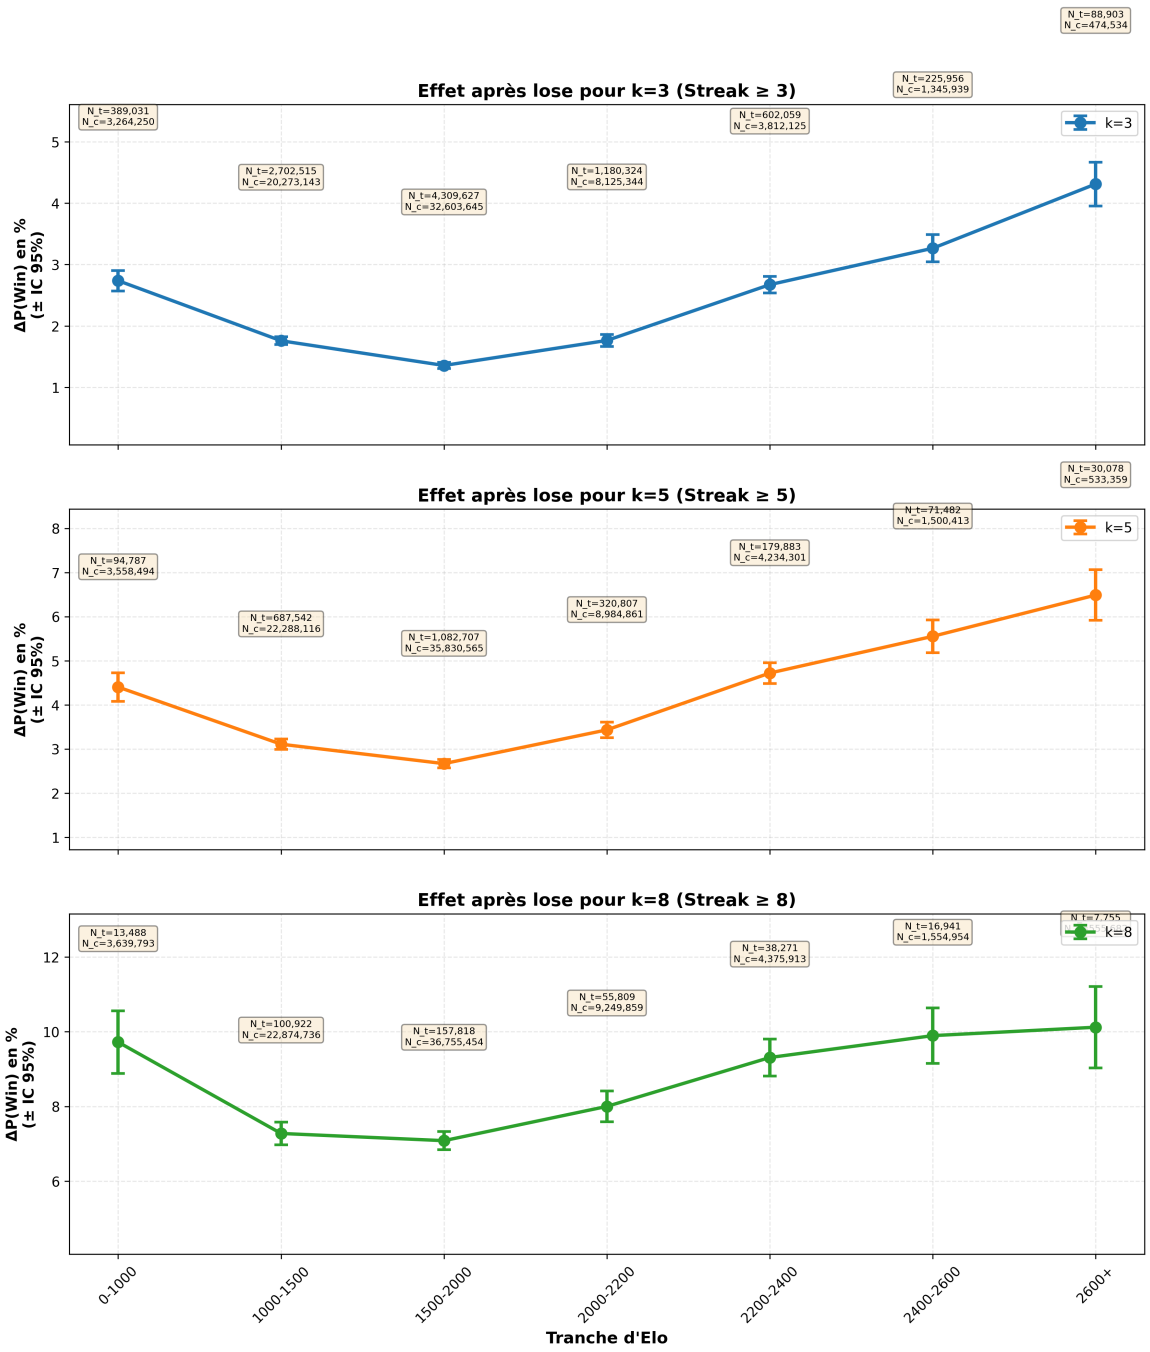

FIGURE 6 – Augmentation de la probabilité de victoire après une défaite en fonction de la tranche elo pour différentes valeurs de streak

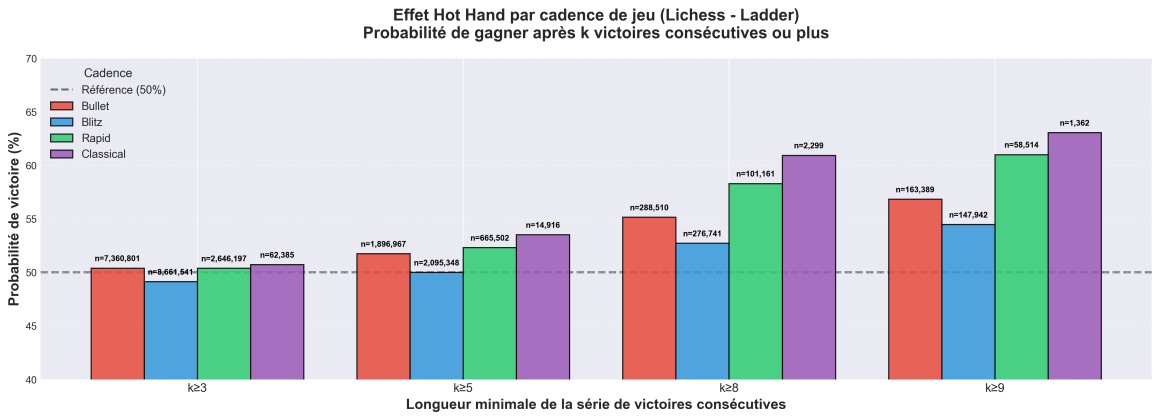

FIGURE 7 – Effet hot hand par cadence de jeu (Lichess - Ladder) : Probabilité de gagner après k victoires consécutives ou plus

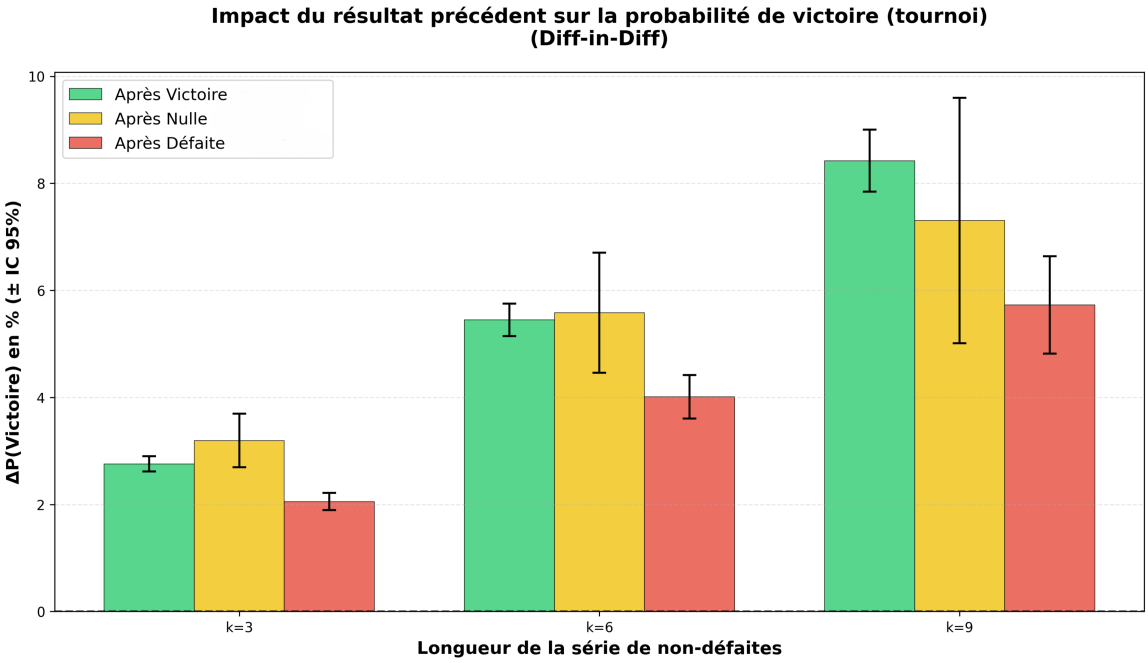

FIGURE 8 – Impact du résultat précédent sur la probabilité de victoire (Tournois) (Diff-in-Diff)

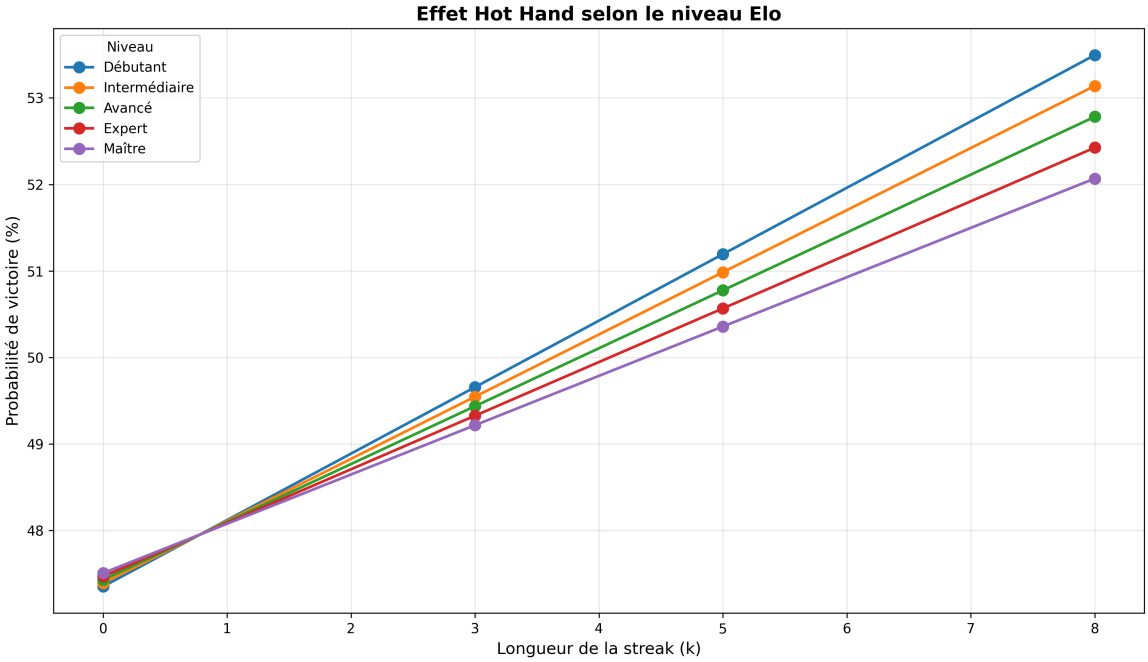

FIGURE 9 – Effet hot hand selon le niveau elo

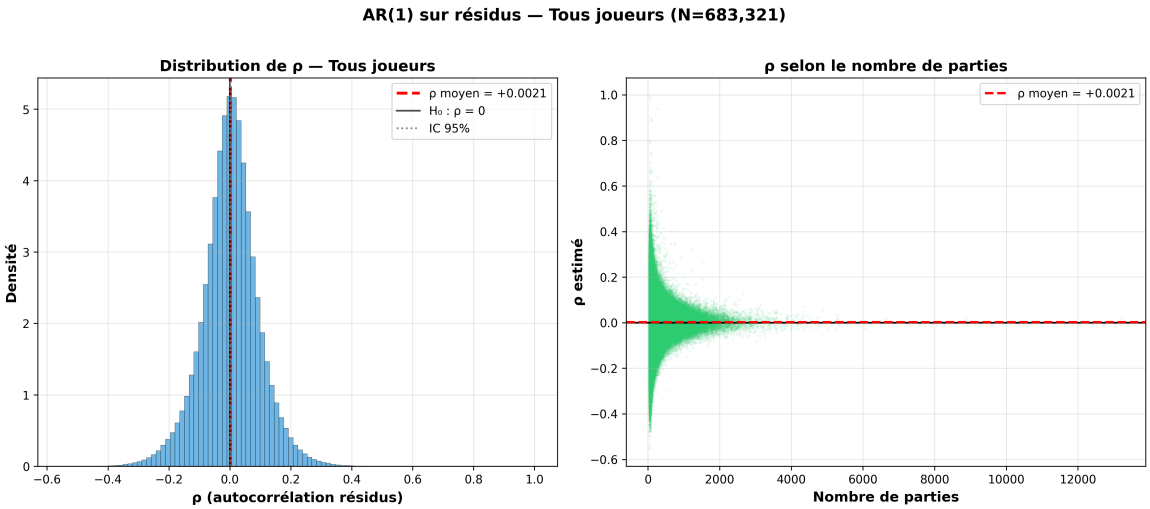

FIGURE 10 – AR(1) sur résidus - Tous joueurs (N=683,321)

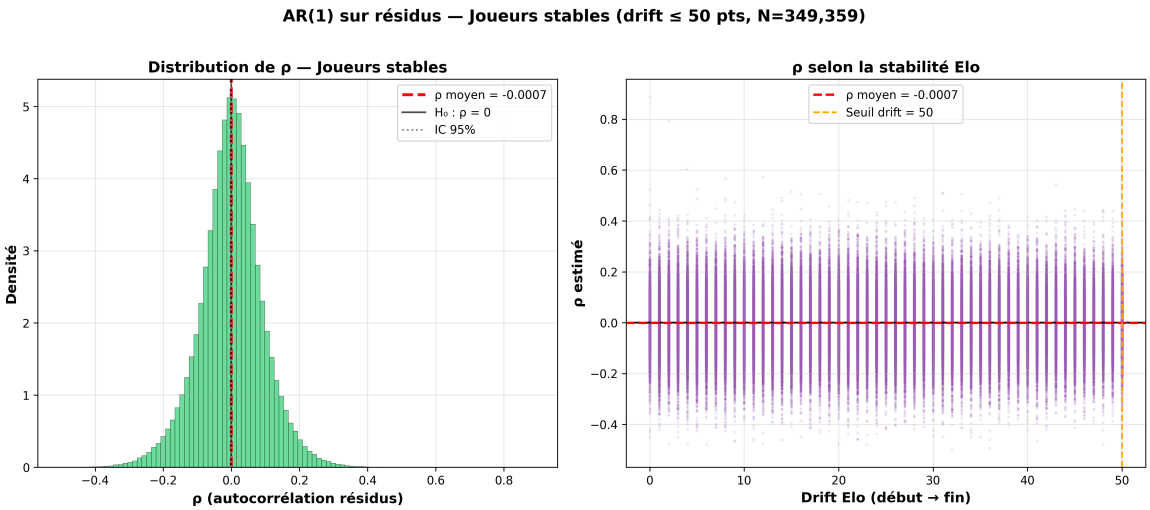

FIGURE 11 – AR(1) sur résidus - joueurs stables (drift $\leq$ 50 pts, N=349,359)